
Identificação do Ácaro Varroa em Abelhas Apis Mellifera por Meio de Inteligência Artificial

LANNA, G.; ARAUJO, I.; KUSAKA, J.; BELARMINO, Y.

Desenvolvimento de Software Multiplataforma

FATEC Registro

10 de junho de 2026

Agenda

- Pitch
- Problematização
- Estado da Arte
- Objetivo
- Ferramental
- Metodologia
- Apresentação prática
- Resultados e Discussões

Duração: 10 a 11 min.

Pitch

- O **MiteScan** é um sistema inteligente para monitoramento de colmeias, que utiliza técnicas de **Aprendizado de Máquina** e **Processamento de Imagens** para detectar precocemente a presença do ácaro *Varroa destructor*.

Diferenciais

- Detecção precoce por imagem
- Monitoramento IoT integrado
- Alertas automáticos ao apicultor

Problematização

- O ácaro *Varroa destructor* é uma das principais ameaças às colônias de abelhas, causando enfraquecimento e morte das colmeias.
- A inspeção manual é demorada, sujeita a erros e depende da experiência do apicultor.
- O **MiteScan** busca automatizar a detecção do parasita, reduzindo perdas e melhorando o manejo apícola.



Fonte: Seu Nome

Estado da Arte

Título/Autores	Objetivo	Método	Resultados	Limitações	Gap
Deep learning beehive monitoring system for early detection of the varroa mite – Voudiotis et al. (2022)	Identificar o ácaro <i>Varroa destructor</i> precocemente nas colmeias.	Duas câmeras (5 MP), microprocessador ARM e modelo de CNN pré-treinado (modos online/offline).	Precisão de 77% a 86% no algoritmo; modo online 3 a 4 vezes mais rápido.	Modo online exige custos com dados; modo offline teve problemas de pareamento Bluetooth.	Uso de modelos pré-treinados e dependência de hardware embarcado de alto custo (ARM quad-core).
Desarrollo de un sistema de reconocimiento y conteo del parásito Varroa destructor en colmenas para probar efectividad de tratamientos – Hernández (2020)	Processar imagens carregadas via web para identificar pontos de infestação.	Bibliotecas OpenCV e Scikit-learn, além de algoritmos não supervisionados como KMeans e DBScan.	Praticamente todas as Varroas foram localizadas, mas com baixíssima precisão final.	Alta taxa de falsos positivos (objetos irrelevantes classificados como Varroa) e fotos de baixa qualidade.	Falta de uma abordagem de aprendizado supervisionado (Deep Learning) dedicada para evitar falsos positivos.
Apisot: An iot function aggregation mechanism for detecting varroa infestation in apis mellifera species – Camayo et al. (2024)	Monitorar umidade, temperatura e gases para alertar risco de infestação por Varroa.	Nós sensores IoT na colmeia, algoritmo multicritério ponderado e rede neural supervisionada.	Precisão de 99% no monitoramento e redução de 75% no consumo de energia da bateria.	Dificuldades na seleção de componentes e sensibilidade à variabilidade climática externa.	Não realiza a análise direta por imagens das abelhas, baseando-se apenas em variáveis ambientais indiretas.

Objetivo

Objetivo Geral

Desenvolver um sistema para a **identificação precoce da Varroa** e monitoramento de umidade e temperatura em colmeias.


Objetivos Específicos

- Desenvolver API integrada aos sistemas Mobile e Web
- Desenvolver algoritmo de Aprendizado de Máquina e Processamento de Imagens
- Identificar precocemente o ácaro *Varroa* e alertar o apicultor
- Monitorar variáveis ambientais e emitir alertas
- Cadastrar colmeias, apicultores e consultar níveis de temperatura

Ferramental

- **Linguagens:** Python
- **Frameworks:** FastAPI
- **Banco de dados:** Supabase
- **Infraestrutura e Hardware:** Arduino UNO, ESP8266, Sensor DHT11
- **Ferramentas:** PyTorch, Torchvision, Pillow, Matplotlib, Seaborn, Scikit-learn
- **APIs e integrações:** API RESTful (FastAPI), Integração IoT-API, Câmera/Interface

Metodologia



Apresentação Prática

- **Demonstração** ao vivo do sistema
- Principais **funcionalidades** implementadas
- **Interface** e experiência do usuário
- Fluxos de **uso** e navegação
- Casos de uso e **cenários** práticos

O que será exibido

Sistema MiteScan em execução, com detecção de ácaro, alertas e dashboard de monitoramento.

Resultados e Discussões

- O modelo atingiu **81%** de acurácia no treinamento e **62%** na validação
- A classe *normal* teve o melhor resultado, enquanto *varroa* e *asa deformada* apresentaram maior confusão devido à semelhança visual
- Os resultados indicam que a ferramenta tem potencial

Acurácia do Modelo

81%

Treinamento

62%

Validação

Obrigado!

